

Probabilità e statistica

Davide Calabrò

January 20, 2020

Probabilità

Funzione probabilità

Definiamo la funzione probabilità come un terna probabilistica (Ω, F, P)

Proprietà

1. $\forall E \in F \rightarrow P(E^c) = 1 - P(E)$
2. $\forall E \in F \rightarrow P(E) \leq 1$
3. se $E \subseteq F \rightarrow P(E) \leq P(F)$ e $P(F \setminus E) = P(F) - P(E)$ (prop. di monotonia)
4. $\forall E, F \in F \rightarrow P(E \cup F) = P(E) + P(F) - P(E \cap F)$

Dimostrazioni

1. $\Omega = E + E^c \rightarrow 1 = P(\Omega) = P(E) + P(E^c) \rightarrow P(E^c) = 1 - P(E)$
2. $0 \leq P(E) \leq 1 - P(E^c) \leq 1$ quindi le P sono comprese tra 0 e 1
3. Definiamo $F = E \cup F \setminus E$ (unione disgiunta)
 $P(F) = P(E) + P(F \setminus E) \rightarrow P(F \setminus E) = P(F) - P(E)$
Inoltre $P(F \setminus E) \geq 0$, per cui $P(F) - P(E) \geq 0$, quindi $P(E) \leq P(F)$
4. Definiamo $E \cup F = (E \cap F) \cup [F \setminus (E \cap F)] \cup [E \setminus (E \cap F)]$ (forma disgiunta)
 $P(F \cup E) = P(E \cap F) + P(F \setminus E \cap F) + P(E \setminus E \cap F) = P(E \cap F) + P(F) - P(E \cap F) + P(E) - P(E \cap F)$
 $P(F \cup E) = P(E \cap F) + P(F) + P(E) - P(E \cap F)$
Intuitivamente l'idea è che se faccio $P(E)$ e $P(F)$ conto l'intersezione 2 volte.

Definizioni e dimostrazioni

0.1 Legge debole dei grandi numeri

Sia X_1, X_2, \dots una successione di variabili aleatorie indipendenti e identicamente distribuite (i.i.d.) con media μ e varianza σ^2 finite. Sia $S_n = X_1 + \dots + X_n$ per ogni $n = 1, 2, \dots$. Allora $\forall \epsilon > 0$

$$\lim_{n \rightarrow \infty} P\left(\left|\frac{S_n}{n} - \mu\right| > \epsilon\right) = 0 \quad (1)$$

0.1.1 Media campionaria

Definiamo $\overline{X}_n := \frac{S_n}{n} = \frac{X_1 + \dots + X_n}{n}$. \overline{X}_n è una v.a. detta media campionaria di $X_1 + \dots + X_n$. Dunque il risultato precedente si può scrivere come:

$$\lim_{n \rightarrow \infty} P(|\overline{X}_n - \mu| > \epsilon) = 0 \quad (2)$$

Dimostrazione Essendo le v.a. i.i.d., per le proprietà della varianza

$$\text{var}(\overline{X}_n) = \text{var}\left(\frac{S_n}{n}\right) = \frac{\sum_{i=1}^n \text{var}(X_i)}{n} = \frac{n \cdot \text{var}(X_1)}{n^2} = \frac{\sigma^2}{n} \quad (3)$$

e per le proprietà della media

$$E(\overline{X}_n) = E\left(\frac{S_n}{n}\right) = \frac{\sum_{i=1}^n E(X_i)}{n} = \frac{nE(X_1)}{n} = \mu \quad (4)$$

Inoltre, la disuguaglianza di Chebyshev per una v.a. Y con varianza finita dice che:

$$P(|Y - E(Y)| > \epsilon) \leq \frac{\text{var}(Y)}{\epsilon^2} \quad (5)$$

che applicata a $Y = \overline{X}_n$

$$0 \leq P(|\overline{X}_n - \mu| > \epsilon) \leq \frac{\sigma^2}{n\epsilon^2} \rightarrow 0 \text{ per } n \rightarrow \infty \quad (6)$$

0.2 Legge forte dei grandi numeri

Sia X_1, X_2, \dots una successione di v.a. i.i.d. che ammettono media μ . Allora:

$$P(\omega : \lim_{n \rightarrow \infty} \overline{X}_n(\omega) = \mu) = 1 \quad (7)$$

dove $\overline{X}_n(\omega) = (X_1(\omega) + \dots + X_n(\omega))/n$. La differenza rispetto alla legge debole è che qui P non tende a 1, ma ci converge proprio.

0.3 Teorema centrale del limite (TCL)

Sia X_1, X_2, \dots una successione di v.a. i.i.d. con media μ e varianza σ^2 finite.
Sia, per ogni $n = 1, 2, \dots$, $S_n = X_1 + \dots + X_n$, allora $\forall x \in \mathbb{R}$

$$\lim_{n \rightarrow \infty} P\left(\frac{S_n - n\mu}{\sqrt{n\sigma^2}} \leq x\right) = \Phi(x) = \int_{-\infty}^x \frac{1}{\sqrt{2\pi}} e^{-\frac{u^2}{2}} du \quad (8)$$

1.

$$E(S_n) = E(X_1 + \dots + X_n) = n\mu \quad (9)$$

$$\text{var}(S_n) = \text{var}(X_1 + \dots + X_n) = n\sigma^2 \quad (10)$$

$$\Rightarrow \frac{S_n - n\mu}{\sqrt{n\sigma^2}} = \frac{S_n - E(S_n)}{\sqrt{\text{var}(S_n)}} \text{ standardizzata} \quad (11)$$

La standardizzata di S_n $\frac{S_n - n\mu}{\sqrt{n\sigma^2}} \approx \mathbb{N}(0, 1) \Rightarrow S_n \approx \mathbb{N}(n\mu, n\sigma^2)$

2.

$$\frac{\frac{S_n - n\mu}{n}}{\frac{\sqrt{n\sigma^2}}{n}} = \frac{\overline{X_n} - \mu}{\frac{\sigma}{\sqrt{n}}} = \frac{\overline{X_n} - E(\overline{X_n})}{\sqrt{\text{var}(\overline{X_n})}} \quad (12)$$

Dunque il TCL posso anche scriverlo come

$$\lim_{n \rightarrow \infty} P\left(\frac{\overline{X_n} - \mu}{\frac{\sigma}{\sqrt{n}}} \leq x\right) = \Phi(x) \quad (13)$$

3. Teorema di Demoivre-Laplace: supponiamo S_n = numero dei successi in n prove di Bernoulli, quindi

$$S_n = X_1 + \dots + X_n, X_i = \begin{cases} 1 & \text{se l'i-esima prova è un successo} \\ 0 & \text{altrimenti} \end{cases} \quad (14)$$

$$S_n \sim Bi(n, p)$$

S_n : somma di n i.i.d. con $X_i \sim Be(p)$

$$E(X_i) = p (= \mu), \text{var}(X_i) = p(1-p) (= \sigma^2)$$

$$P\left(a \leq \frac{S_n - np}{\sqrt{np(1-p)}} \leq b\right) = P\left(\frac{S_n - np}{\sqrt{np(1-p)}} \leq b\right) - P\left(\frac{S_n - np}{\sqrt{np(1-p)}} \leq a\right) \xrightarrow[n \rightarrow \infty]{TCL} \Phi(b) - \Phi(a) \quad (15)$$

0.4 Inferenza parametrica - definizioni

0.4.1 Stimatore puntuale

Uno stimatore puntuale di $K(\theta)$ è una statistica $K = d_n(X_1, \dots, X_n)$ usata per fare inferenza su $k(\theta)$

Stimatore e stima Se $X_1 = x_1, \dots, X_n = x_n$ è un'osservazione campionaria e $K_n = d_n(X_1, \dots, X_n)$ è uno STIMATORE di $K(\theta)$ allora $\hat{K}_n = d_n(X_1, \dots, X_n)$ è detta STIMA di $K(\theta)$, che è circa il valore di \hat{K}_n in corrispondenza delle osservazioni. Dunque lo STIMATORE è una v.a., mentre la STIMA è un numero

0.4.2 Proprietà degli stimatori puntuali

X_1, \dots, X_n campione aleatorio da f_θ e sia $K(\theta)$ una caratteristica della popolazione di densità f_θ .

$$D_n = d(X_1, \dots, X_n) \text{ stimatore di } K(\theta) \quad (16)$$

Errore quadratico medio Sia X_1, \dots, X_n campione aleatorio estratto da f_θ e sia D_n uno stimatore di $K(\theta)$. Si definisce ERRORE QUADRATICO MEDIO di D_n come stimatore di $K(\theta)$ la funzione del parametro θ

$$r(d, K(\theta)) := E_\theta[(D_n - K(\theta))^2] = E_\theta[(d(X_1, \dots, X_n) - K(\theta))^2] \quad (17)$$

Mentre nel caso assolutamente continuo abbiamo:

$$r(d, K(\theta)) = \int_{\mathbb{R}^n} (d(x_1, \dots, x_n) - K(\theta))^2 f_\theta(x_1) \dots f_\theta(x_n) dx_1 \dots dx_n \quad (18)$$

Distorsione Sia X_1, \dots, X_n campione aleatorio da f_θ e sia D_n uno stimatore di $K(\theta)$. Si definisce DISTORSIONE (o bias) di $D_n = d(X_1, \dots, X_n)$ come stimatore di $K(\theta)$ e la funzione di θ

$$b(d, K(\theta)) := E_\theta(D_n) - K(\theta) \quad (19)$$

Lo stimatore D_n si dice non distorto per $K(\theta)$ se

$$b(d, K(\theta)) = 0, \forall \theta \quad (\iff E_\theta(D_n) = K(\theta), \forall \theta) \quad (20)$$

Osservazioni

1. Se D_n è non distorto per $K(\theta)$

$$\Rightarrow r(d, K(\theta)) := E_\theta[(D_n - K(\theta))^2] = E_\theta[(D_n - E_\theta(D_n))^2] = \text{var}_\theta(D_n)$$

2. Decomposizione dell'errore quadratico medio di $D_n = d(X_1, \dots, X_n)$ come stimatore di $K(\theta)$

$$r(d, K(\theta)) = E_\theta[(D_n - K(\theta))^2] \quad (21)$$

Sapendo che $\text{var}(Y) = E(Y^2) - E(Y)^2$, otteniamo:

$$= \text{var}_\theta(D_n - K(\theta)) + [E_\theta(D_n - K(\theta))]^2 = \text{var}_\theta(D_n) + [b(d, K(\theta))]^2 \quad (22)$$

Principio di invarianza degli MLE Se $\hat{\theta}_n$ è MLE di θ e $K(\theta)$ è una caratteristica della popolazione, allora $K(\hat{\theta}_n)$ è MLE di $K(\theta)$

0.4.3 Proprietà asintotiche degli stimatori

Distorsione Una successione $(D_n = d_n(X_1, \dots, X_n))_n$ di stimatori di $K(\theta)$ è detta ASINTOTICAMENTE NON DISTORTA se

$$b(d_n, K(\theta)) = E_\theta(D_n) - K(\theta) \rightarrow 0 \text{ per } n \rightarrow \infty \quad (\Leftrightarrow E_\theta(D_n) \rightarrow K(\theta) \forall \theta)$$

Consistenza debole Una successione $(D_n = d_n(X_1, \dots, X_n))_n$ di stimatori di $K(\theta)$ è detta DEBOLMENTE CONSISTENTE se $\forall \epsilon > 0$ vale

$$P_\theta(|D_n - K(\theta)| > \epsilon) \rightarrow 0 \text{ per } n \rightarrow \infty$$

Consistenza in media quadratica Una successione $(D_n = d_n(X_1, \dots, X_n))_n$ di stimatori di $K(\theta)$ è detta CONSISTENTE IN MEDIA QUADRATICA se

$$r(d_n, K(\theta)) := E_\theta[(D_n - K(\theta))^2] \rightarrow 0 \text{ per } n \rightarrow \infty$$

Osservazioni

- Se $(D_n)_{n \geq 1}$ è CONSISTENTE IN MEDIA QUADRATICA, allora la successione è anche DEBOLMENTE CONSISTENTE
- Data $r(d_n, K(\theta)) = \text{var}(D_n) + [b(d_n, K(\theta))]^2$, se $\text{var}(D_n) \rightarrow 0$ per $n \rightarrow \infty$ $\forall \theta$ e $(D_n)_n$ è ASINTOTICAMENTE NON DISTORTA, allora $(D_n)_n$ è CONSISTENTE IN MEDIA QUADRATICA

0.5 Quantità pivotali

Si definisce QUANTITÀ PIVOTALE una v.a. $Q = q(X_1, \dots, X_n, \theta)$ la cui distribuzione non dipende da θ . Si noti che la quantità pivotale non è una statistica, in quanto dipende da θ

0.6 Verifica di un'ipotesi statistica

Un'IPOTESI STATISTICA è un'affermazione su uno o più parametri della distribuzione della popolazione.

0.6.1 Regione critica e livello di significatività di un test

Consideriamo una popolazione avente distribuzione F_θ che dipende da un parametro incognito θ e supponiamo di voler verificare una qualunque ipotesi su θ che chiameremo IPOTESI NULLA e che indicheremo con \mathbb{H}_0

Def. Un'ipotesi statistica si dice SEMPLICE se caratterizza completamente la distribuzione della popolazione, altrimenti è detta COMPOSTA

Def. Un test per la verifica di un'ipotesi \mathbb{H}_0 ha REGIONE CRITICA $C \subseteq \mathbb{R}^n$ se osservando $X_1 = x_1, \dots, X_n = x_n$

- ACCETTO \mathbb{H}_0 se $(X_1, \dots, X_n) \in C$
- RIFIUTO \mathbb{H}_0 se $(X_1, \dots, X_n) \notin C$

Errori

- Commettiamo un errore di 1^a specie quando i dati ci portano a rifiutare \mathbb{H}_0 e \mathbb{H}_0 è corretta
- Commettiamo un errore di 2^a specie quando i dati ci portano ad accettare \mathbb{H}_0 e \mathbb{H}_0 è falsa

Attenzione L'errore di 1^a specie è più grave!

Livello di significatività Si definisce livello di significatività α quel valore tale per cui

$$P(\text{errore di 1}^a \text{ specie}) = P(\text{Rifiutare } \mathbb{H}_0) \leq \alpha$$

p-value Data una famiglia di test, al variare del livello di significatività, si definisce P-VALUE il più piccolo valore della significatività per cui rifiuto \mathbb{H}_0 con i dati a disposizione. Quindi $\alpha \geq p\text{-value} \rightarrow \text{rifiuto } \mathbb{H}_0$, accetto altrimenti.

Curva OC Si definisce CURVA OC del test la funzione del parametro incognito μ

$$B(\mu) := P_\mu(\text{accettare } \mathbb{H}_0)$$

quindi se μ soddisfa l'ipotesi alternativa \mathbb{H}_1 allora $B(\mu)$

$$B(\mu) = P_\mu \left(-z_{\alpha/2} < \frac{(\overline{X}_n - \mu_0)}{\sigma_0} \sqrt{n} < z_{\alpha/2} \right)$$

Attenzione $\frac{(\overline{X_n} - \mu_0)}{\sigma_0} \sqrt{n}$ non è una gaussiana standard, per la presenza di μ_0 al posto di μ

Potenza Si definisce potenza rispetto al parametro μ

$$\pi(\mu) := 1 - B(\mu)$$